Compiladores

Aulas práticas

© 2010 Pedro Freire

Este documento tem alguns direitos reservados:



Atribuição-Uso Não-Comercial-Não a Obras Derivadas 2.5 Portugal http://creativecommons.org/licenses/by-nc-nd/2.5/pt/

Isto significa que podes usá-lo para fins de estudo.

Para outras utilizações, lê a licença completa. Crédito ao autor deve incluir o nome ("Pedro Freire") e referência a "www.pedrofreire.com".

REQUISITOS	6
PARA A ESCOLA	6
PARA O ALUNO	6
AULA 01	7
Primeiro exemplo	7
COMPILAR E CORRER	7
INTRODUÇÃO AO FORMATO DE FICHEIROS FLEX	8
FUNCIONAMENTO DAS REGRAS FLEX	8
AULA 02	10
AULA 03	12
Exercícios	12
AULA 04	13
AULA 05	15
Exercícios	16
AULA 06	17
START CONDITIONS	17
AULA 07	19
FORMATO DE FICHEIROS FLEX EM DETALHE	19
USAR FICHEIROS EM VEZ DE STDIN E STDOUT	21
REJECT, YYMORE() E OUTRAS FUNCIONALIDADES FLEX	22
EXEMPLO FINAL 1: CALCULADORA DE INTEIROS, PÓS-FIXA	22
EXEMPLO FINAL 2: CONTADOR DE IDENTIFICADORES	22
EXERCÍCIO FINAL FLEX	23
AULA 08	24
PRIMEIRO EXEMPLO BISON	24
A GRAMÁTICA DA CALCULADORA	25
Análise gramatical: yyparse()	25
SÍMBOLOS TERMINAIS E VALORES SEMÂNTICOS	26
INTERLIGAÇÃO ENTRE OS FICHEIROS FLEX E BISON	27
FORMATO DO FICHEIRO BISON	28
EXERCÍCIO	28
AULA 09	29
REGRAS BISON	29
COMO FUNCIONAM AS REGRAS NO PRIMEIRO EXEMPLO	29
EXEMPLO DE ANÁLISE GRAMATICAL	30
CONFLITOS SHIFT/REDUCE: %LEFT, %RIGHT E %EXPECT	31
EXERCÍCIO 1	32
EXERCÍCIO 2	33
EXERCÍCIO 3	33
AULA 10	34

B]	BLIOGRAFIA	.37
Αl	JLA 11	36
	EXERCÍCIO 2	.35
	EXERCÍCIO 1	
	MÚLTIPLOS TIPOS DE DADOS SEMÂNTICOS: %UNION	.34

Requisitos

Para a escola

Requisitos para as salas das aulas práticas de Compiladores:

- Um qualquer Linux instalado, desde que suporte o flex e o bison, nativo, em dual-boot ou máquina virtual (VirtualPC ou VMware). Pode ainda ser acedido remotamente via Telnet/SSH. Pode também ser usado Windows (versão 95 ou acima), desde que funcional em relação aos pontos seguintes.
- flex e bison instalados no sistema operativo, e assegurar a existência do compilador de C (gcc ou cc) assim como do seu correspondente utilitário make, acessíveis a partir de qualquer directório (ou seja, instalados no path).
- No caso do Linux, assegurar que este tem ambiente visual instalado de fácil acesso (par utilizador+senha), assim como editor de texto visual (à semelhança do Bloco de Notas do Windows).
- Acesso à Internet com um browser.

Deve haver 1 PC por aluno.

Cada aula está programada para uma duração de 1,5h.

Para o aluno

Comparência nas aulas. Este guião tem propositadamente omissos certos elementos importantes para a compreensão total da matéria (notas históricas, relações entre partes diferentes da matéria, avisos sobre erros comuns, etc., ou seja, elementos para uma nota 20), embora seja suficiente para passar com nota bastante acima de 10.

Deves ter instalado o flex e o bison em computador próprio se quiseres acompanhar a matéria em casa. Consulta www.pedrofreire.com para uma pequena introdução de como o fazer. Vê também a secção acima para requisitos. Não é no entanto de todo necessário que tenhas estes sistemas em casa para conseguires passar à cadeira (podes usá-los na escola).

Esta cadeira assume que já tens experiência de programação na linguagem C.

Introdução e contextualização: o flex e o bison. Hiperligações.

Seu uso no desenho de compiladores.

Expressões regulares e gramáticas.

Referências e avaliação.

Primeiro exemplo

Primeiro exemplo flex (encontra números inteiros):

```
%option main
 #include <stdio.h>
%%
         puts( yytext );
[0-9]+
.|\n|\r
```

Grave este exemplo como aula01.1 (a extensão é por convenção um "L" minúsculo).

Compilar e correr

Para compilar este programa precisa de ter o flex instalado, assim como um compilador de C qualquer. Então, numa linha de comandos / consola / terminal, execute:

```
flex aula01.1
```

Isto irá criar um ficheiro lex.yy.c que deverá ser compilado na linha de comandos ou no seu compilador favorito. Por exemplo, com o compilador da GNU, faça:

```
gcc lex.yy.c
```

Isto cria um ficheiro executável, cujo nome depende do compilador. Com o compilador da GNU (e a maior parte dos compiladores Unix) é criado um ficheiro a.out. Corra-o:

```
./a.out
```

Em Windows seria apenas

já que o compilador da GNU cria um ficheiro a. exe neste sistema.

O programa parece não fazer nada. É normal: está a ler dados do teclado. Escreva qualquer coisa que inclua números: ele repete os números (cada inteiro numa linha diferente) e ignora o resto. Quando tiver terminado use Ctrl+C para sair. Este é o 1º exemplo flex.

Em programas futuros vai ser prático testar o mesmo texto vezes sem conta. Para evitar termos de escrever sempre o mesmo texto no teclado, podemos colocá-lo num ficheiro separado (e.g.: teste.txt) e depois fazer:

```
./a.out < teste.txt
ou
a < teste.txt
```

Desta vez o programa irá mostrar imediatamente os resultados e sair, sem pausa.

Introdução ao formato de ficheiros flex

Os ficheiros flex têm o seguinte aspecto mínimo:

```
Definições flex
%%
Regras flex
```

No primeiro exemplo, acima, a secção de definições tem uma directiva **%option** do flex para criar uma função main() básica que avalia as expressões regulares a partir do teclado, e uma directiva #include para o código C usado. Os espaços atrás do #include são importantes!

A secção de regras flex tem sempre várias linhas com o seguinte aspecto:

```
expressão-regular acção
```

Cada acção pode ser vazia (não fazer nada), ser só o caracter "|" (que significa "a mesma acção da expressão regular seguinte") ou ser código em C. Pode-se ter mais de uma linha de código em C se este estiver envolvido em {}.

Este ficheiro será analisado em mais detalhe em aula posterior.

Funcionamento das regras flex

O código gerado pelo flex, vai analisar os dados de entrada (tipicamente o teclado) à procura de qual expressão regular se aplica:

- Assim que uma se aplica, corre a acção correspondente, "consome" os caracteres dos dados de entrada que foram "encontrados" pela expressão regular, e repete todo o processo.
- Se mais do que uma se aplica, usa a que "encontra" mais caracteres, ou a primeira do ficheiro se "encontrarem" a mesma quantidade de caracteres.
- Se nenhuma se aplica, exibe um caracter dos dados de entrada no ecrã, "consome-o" e repete o processo.

No exemplo acima, queremos exibir números inteiros no ecrã, e mais nada. A primeira regra exibe os números: a expressão regular

$$[0-9]+$$

detecta números inteiros (como veremos mais tarde), e a acção

exibe o número que foi encontrado no ecrã, uma vez que a variável yytext do flex contém a *string* de dados de entrada que foi encontrada pela expressão regular.

Para evitar que "outros" caracteres sejam exibidos no ecrã (só queremos exibir os números inteiros, e o comportamento do flex quando não encontra uma expressão é exibir esse caracter no ecrã), temos de anular o comportamento habitual do flex.

Para isso criamos uma regra que se aplique a qualquer caracter (mas só 1). Essa expressão regular é:

e associamos a essa expressão regular uma acção vazia.

Expressões regulares comuns:

Caracteres			
Cada carac	Cada caracter "não especial" representa-se a si mesmo		
. (ponto)	Representa qualquer caracter (só 1), excepto o fim-de-linha (EOL)		
[c]	Conjuntos ("classes de caracteres") – representam 1 só caracter; c pode conter caracteres avulso (sem separadores, e.g.: [abc]) ou gamas (ranges) (e.g.: [a-z]); se o 1º caracter de c for ^, o conjunto é todos os caracteres excepto aqueles em c		
Repetições			
C*	O caracter c repetido zero ou mais vezes		
C+	O caracter c repetido uma ou mais vezes		
c?	"Opcional" – o caracter C zero ou uma vez		
c {#}	O caracter c repete-se exactamente # vezes		
c {#,}	O caracter C repete-se # ou mais vezes ($\{0,\}=*,\{1,\}=+$)		
C{# ₁ ,# ₂ }	O caracter c repete-se no mínimo $\#_1$ vezes, e no máximo $\#_2$ vezes ($\{0,1\}=?$)		
Agrupamentos			
(r)	Agrupamento de expressões (e.g.: para fazer com que uma repetição se aplique a mais do que um caracter)		
r s	"ou"		

Todas as expressões de repetição (*, +, ? e {}) são gananciosas* (greedy).

O "ou" também é greedy: avalia as expressões da esquerda para a direita e escolhe a que consumir mais caracteres.

© 2010 Feuro . . c.. www.pedrofreire.com © 2010 Pedro Freire // Compiladores

^{*} Há autores que as chamam de "gulosas".

Exemplos, assumindo que o utilizador escreve

Copacabana

quando corre o programa flex:

• Com a expressão: a.a são encontradas (matched) as seguintes ocorrências marcadas com fundos verde e amarelo (cores intercaladas para cada ocorrência):

Note-se que a sequência sobreposta "aba" não é encontrada.

• Com a expressão: [abc]

são encontradas: Copacabana

• Com a expressão: [A-Z]

é encontrada: Copacabana

• Com a expressão: a.*a

é encontrada: Copacabana (* é ganancioso)

• Com a expressão: (a.)*

é encontrada: Cop<mark>acaban</mark>a

• Com a expressão: a.?

são encontradas: Copacabana

Mais exemplos:

- Expressão para detectar um número de PIN ("####"):
 [0-9] {4}
- Expressão ingénua para detectar um dos 4 números de um número IP: [0-9]{1,3}
- Expressão ingénua para detectar uma string:

(as aspas têm de ser representadas como ["] – veremos porquê mais tarde).

Problema: com o texto: var="a"+x+"b"; esta expressão encontra: var=<mark>"a"+x+"b"</mark>; (porque o * é ganancioso)

• Expressão melhorada para detectar uma string:

Com o texto: var="a"+x+"b"; esta expressão encontra: var=<mark>"a"</mark>+x+<mark>"b"</mark>;

É um erro comum não reparar que [ana] ≠ ana.

Exemplos resolvidos:

1. Lista de inteiros separados por vírgulas (e.g.: "1,2,3,4"). Se vamos ter uma lista, precisamos de usar uma expressão de repetição (*, +, etc.), mas aquilo que se repete (um inteiro seguido de uma vírgula) já não se repete no último elemento (que deixa de ter vírgula à direita). A solução é exprimi-lo outra vez:

$$([0-9]+,)*[0-9]+$$
 ou $[0-9]+(,[0-9]+)*$

2. Número inteiro entre 1 e 20.

Não conseguimos validar gamas numéricas (apenas gamas de caracteres). Então validamos gamas numéricas pelo seu aspecto (em termos de caracteres):

Ou seja:

20 ou 10-19 ou 1-9

Note-se no "ou" a ordem dos mais longos para os mais curtos!

Exercícios

Exercícios flex com expressões regulares:

- 1. Matrículas portuguesas
- 2. Idade (1 a 150 inclusive)
- 3. Nº de cartão de crédito (opcionalmente separado por "-" ou espaço a cada 4 dígitos)
- 4 IPv4
- 5. Número real (inteiro, com parte decimal opcional e parte científica opcional)

Os 2 primeiros serão resolvidos no quadro nos últimos 20min.

Correcção na aula seguinte.

Resolução dos exercícios da aula anterior:

1. As matrículas têm os seguintes aspectos válidos:

```
##-##-LL
  ##-LL-##
  LL-##-##
onde # é um dígito numérico e L uma letra maiúscula.
Isto não funciona porque permite combinações inválidas:
   (([0-9]{2}|[A-Z]{2})-){2}([0-9]{2}|[A-Z]{2})
Então temos mesmo de ter as 3 opções diferentes na expressão:
   ([0-9]{2}-[0-9]{2}-[A-Z]{2})
   ([0-9]{2}-[A-Z]{2}-[0-9]{2})
   ([A-Z]{2}-[0-9]{2}-[0-9]{2})
```

2. Validamos gamas numéricas pelo seu aspecto (em termos de caracteres):

```
[1-9] | [1-9] [0-9] | 1 [0-4] [0-9] | 150
Ou seia:
   1-9 ou 10-99 ou 100-149 ou 150
Simplificando:
```

[1-9][0-9]?|1[0-4][0-9]|150

3. Os números de cartão de crédito têm os seguintes aspectos válidos:

```
##################
####-###-####
#### #### ####
```

(na mesma linha e sem espaços)

onde # é um dígito numérico. O enunciado permite maior flexibilidade, e.g.: #### #######-####

Logo a expressão será uma lista de 4 grupos de 4 dígitos numéricos cada: $([0-9]{4}[-]?){3}[0-9]{4}$

Note-se que o espaço separa uma expressão regular da acção correspondente: como tal, ele deve ser escaped para ser usado numa expressão regular. Neste

caso, ao ser usado num conjunto, ele é automaticamente escaped.

4. Um número IP versão 4 tem o seguinte aspecto:

```
#.#.#.#
onde # é um numero de 0 a 255 inclusive.
A expressão será então uma lista de 4 números:
   (r[.]){3}r
onde r é a expressão regular para um número entre 0 e 255:
   [0-9] | [1-9] [0-9] | 1 [0-9] {2} | 2 [0-4] [0-9] | 25 [0-5]
que, simplificada e com os parêntesis, fica:
   ((2[0-4]|1[0-9]|[1-9])?[0-9]|25[0-5])
```

5. Um número real pode ter os seguintes aspectos válidos, e.g.:

```
15
+8
-0.5
.7
2.
3.001
3E8
+8.6E-8
```

Se verificarmos, isto significa que, à excepção de ".7" e "2.", o formato de um número real é:

```
##(.#)?(E±#)?
onde # representa um número inteiro. Então, em expressão regular:
[+-]?[0-9]+([.,][0-9]+)?([Ee][+-]?[0-9]+)?
```

Mas e o ".7" e "2."? Não podemos simplesmente substituir os dois primeiros + de repetição por * porque isso permitiria que "." e "+.", entre outros, fossem considerados números reais. Então temos de exprimir os 3 casos possíveis de forma a excluir o 4º caso inválido:

[+-]?([0-9]+([.,][0-9]*)?|[.,][0-9]+)([Ee][+-]?[0-9]+)? onde o que está a cor mais clara é a parte modificada da expressão anterior.

Expressões regulares específicas do flex:

Caracteres	Caracteres e escapes		
[[:c:]]	Conjunto pré-definido ("expressões de classes de caracteres") – ver manual do flex		
" S "	S" S literal – para usar em S o próprio caracter ", fazer \", e para usar o próprio fazer \\		
\c	Se c for 0, a, b, f, n, r, t ou v, então é o caracter ANSI-C correspondente, caso contrário é um c literal (usado para fazer escaping de caracteres especiais)		
\###	Caracter com o código ASCII octal ###		
\x##	Caracter com o código ASCII hexadecimal ##		
Expressões			
{n}	Expansão de n, sendo n um nome (ver exemplo, abaixo)		
r/s	Encontra r apenas se for seguido por s (s não fará parte de yytext); nem todos as expressões regulares podem ser usadas em s – ver manual do flex		
Âncoras	Âncoras		
^	Neste sítio tem de existir o início de uma linha		
\$	Neste sítio tem de existir o fim de uma linha		
< <e0f>></e0f>	Neste sítio tem de existir o fim do ficheiro / dos dados de entrada; a acção por omissão para este tipo de âncora é um return que termina a execução da função gerada pelo flex		

As âncoras não representam caracteres. Representam sim, posições no ficheiro ou nos dados de entrada (ver exemplo abaixo).

Exemplo:

```
%option main
    #include <stdio.h>
DIGITO [0-9]
%%

{DIGITO}+    printf( "Encontrei o inteiro %s\n", yytext );
"aluno[s]"    puts( "Encontrei a expressão \"aluno[s]\"" );
^Ze$         puts( "Encontrei \"Ze\" sozinho numa linha" );
<<EOF>>         puts( "Encontrei o fim do ficheiro" ); return;
.|\n|\r
```

Para testar o EOF, faça Ctrl+D em Unix ou Ctrl+Z em Windows.

Questão: porquê %s no printf()?

Exercícios

Faça um pequeno programa flex para:

Comentários C++ //...
 Comentários C /*...*/
 Strings C/C++ "...\"..."

Correcção na aula seguinte.

Resolução dos exercícios da aula anterior:

```
1. "//".* ou [/][/].* ou \/\/.*
2. Primeira hipótese:
        "/*".*"*/"
  Para apanhar EOL:
        "/*"(. |\n|\r)*"*/" (usar Ctrl+D/Z ao testar)
  Para evitar comportamento ganancioso:
        "/*"([^*]|[*]+[^/])*"*/"
  Para aceitar ****/:
        "/*"([^*]|[*]+[^/])*[*]+[/]
3. ["]([^\\"]|\\["])*["]
  Para aceitar qualquer código de escape oferecido pelo C:
  ["]([^\\"]|\\([^0-7xX]|0|[0-7]{3}|[xX][0-9a-fA-F]{2}))*["]
```

Start Conditions

Start condition (condição de arranque) é um estado em que o flex se encontra. Dependendo desse estado, uma ou mais regras deixam de ter efeito (deixam de estar activas).

Declaramos as start conditions na secção de definições:

Declarar start conditions		
%S S	Start condition inclusiva: quando estiver activa, as regras sem start condition definida, ou com as start conditions 5 ou * serão as únicas activas	
%x s	Start condition exclusiva: quando estiver activa, apenas as regras com as start conditions S ou * estarão activas	

A start condition INITIAL (ou 0) está pré-definida.

Troca-se de start condition com a chamada BEGIN(5) em qualquer bloco de código em C. Pode-se ler a start condition actual num bloco C lendo a macro YY START. Existem ainda funções para gerir uma pilha de start conditions (ver manual do flex e % option stack).

Especificamos que regras pertencem a que *start conditions* com:

```
Start conditions
   <*>r
              A expressão regular r estará activa em qualquer start condition,
              mesmo uma exclusiva
   <s>r
              A expressão regular r estará activa apenas na start condition 5
              A expressão regular r estará activa apenas nas start conditions 51
\langle s_1, s_2 \rangle r
              e s_2
   < 5 > {
              As expressões regulares r<sub>1</sub>, r<sub>2</sub> e r<sub>3</sub> estarão activas apenas no
              âmbito (scope) da start condition 5
    r_1
    r_2
    r_3
     }
```

Exemplo: Programa flex que recebe um ficheiro ASP ou PHP e "retira-lhe" o HTML e CSS, exibindo apenas todo o código server-side:

```
%option main
  #include <string.h>
%x ASP
%x PHP
%%
"<%"=?
                       BEGIN( ASP );
"<?"(=|php)?
                       BEGIN( PHP );
.|\n|\r
<ASP>"%>"
                       BEGIN( INITIAL );
<PHP>"?>"
                       BEGIN( INITIAL );
<ASP,PHP>.|\n|\r
                       ECHO;
```

ECHO é uma macro definida pelo flex que simplesmente exibe yytext e então equivale a:

```
fputs( yytext, yyout );
```

onde yyout (variável do flex) é normalmente stdout (ecrã). Veremos em aula posterior como podemos dizer ao flex para exibir os resultados num ficheiro.

Exercício: Repetir os exercícios da aula anterior, mas recorrendo a *start conditions*. Correcção na aula seguinte.

Resolução dos exercícios da aula anterior:

```
C++
```

```
%option main
    %x COMENT
    %%
    "//"
                      BEGIN( COMENT );
    .|\n|\r
    <COMENT>.
                      ECHO;
    <COMENT>\n|\r
                      BEGIN( INITIAL );
C
    %option main
    %x COMENT
    %%
    "/*"
                      BEGIN( COMENT );
    .|\n|\r
    <COMENT>"*/"
                      BEGIN( INITIAL );
    <COMENT>.|\n|\r ECHO;
Strings
    %option main
      #include <stdio.h>
    %x STR
    %%
    ["]
                      BEGIN( STR );
    .|\n|\r
                      BEGIN( INITIAL );
    <STR>["]
    <STR>\\["]
                      putchar( '"' );
    <STR>.
                      ECHO;
```

Exercícios de revisão (na aula).

Formato de ficheiros flex em detalhe

Como foi visto na 1ª aula, os ficheiros flex têm o seguinte aspecto geral:

```
Definições flex
%%
Regras flex
Código de utilizador em C
```

A secção de definições pode ter:

```
Inicializações de variáveis C e funções/protótipos C
(opcional, podem também ser linhas indentadas, sem %{ %})
%directiva
/* Comentário, copiado para o ficheiro C final */
nome expressão-regular
```

No último exemplo da aula anterior, temos as directiva %option e %x do flex, e uma directiva #include para o código C usado.

A secção de regras flex tem o seguinte aspecto:

```
Inicializações de variáveis e código C locais à função
yylex() (opcional, podem também ser linhas indentadas,
sem %{ %})
%}
expressão-regular acção
```

Cada acção pode ser vazia (não fazer nada), ser só o caracter "|" (que significa "a mesma acção da expressão regular seguinte") ou ser código em C. Pode-se ter mais de uma linha de código em C se este estiver envolvido em {}.

A expressão regular está separada da sua acção por um ou mais espaços ou tabs. Isto significa que estes caracteres devem estar escaped na expressão regular para serem usados como parte da expressão (escaped significa usar [] à volta do espaço, por exemplo – mais sobre isso em aula anterior).

A função yylex() é uma função criada pelo flex no código C gerado, função essa que corre as expressões regulares e as acções que lhes correspondem. Note-se que no primeiro exemplo da aula 01, %option main gera a seguinte função main():

```
int main( void )
yylex();
return 0;
```

Estas regras vão ser convertidas para código C dentro de uma função yylex(). É por esta razão que a 3ª secção, que o flex simplesmente copia para o ficheiro final, tem a função main() a chamar yylex().

Na secção de código de utilizador costuma ter-se a nossa função main() e outras funções, variáveis e estruturas necessárias ao programa. Devido à %option main usada, estas são criadas automaticamente pelo que o exemplo acima não tem esta secção.

Usar ficheiros em vez de stdin e stdout

O flex permite trabalhar com ficheiros em vez da entrada e saídas padrão (stdin e stdout respectivamente):

```
Trabalhar com ficheiros

yyin FILE* de onde o flex lê os dados

yyout FILE* para onde a macro ECHO do flex escreve dados

yyrestart(FILE*) Função flex para alterar yyin – alterar yyin directamente não funciona como se espera porque o flex faz caching/buffering de yyin.
```

Para exemplificar, vamos criar um programa flex que converte ficheiros com terminações de linha Unix (apenas \n) e MacOS antigo (apenas \r) em Windows (\r\n). Ele recebe o nome de dois ficheiros na linha de comandos: o primeiro é o ficheiro origem, e o segundo é o nome destino para esse ficheiro, após conversão.

```
%option nostdinit noyywrap
  #include <stdio.h>
%x EOL MAC
%%
١r
                 fputs("\r\n", yyout); BEGIN(EOL_MAC);
                 fputs("\r\n", yyout);
\n
[^\r\n]+
                 ECHO:
<EOL MAC>\n
                 BEGIN(INITIAL);
<EOL MAC>\r
                 fputs("\r\n", yyout);
<EOL MAC>.
                 ECHO; BEGIN(INITIAL);
%%
int main( int argc, char *argv[] )
if(argc >= 3)
      yyrestart( fopen(argv[1], "r") );
      yyout = fopen( argv[2], "w" );
      yylex();
      fclose( yyout );
      fclose( yyin );
return 0;
```

Neste exemplo, como estamos a pedir ao flex para não inicializar as variáveis yyin e yyout (no %option nostdinit), podíamos substituir a linha yyrestart() por

```
yyin = fopen( argv[1], "r" );
```

REJECT, yymore() e outras funcionalidades flex

O flex tem algumas outras macros e funções definidas para nos auxiliarem a criar programas. Estas devem ser consultadas no manual do flex. Entre as funções que poderão ser de mais interesse e que deves consultar encontram-se o REJECT eo yymore().

Exemplo final 1: Calculadora de inteiros, pós-fixa

Este exemplo flex pretende ser uma calculadora de inteiros com suporte às 4 operações básicas, em modo pós-fixo (postfix, também chamada de calculadora RPN – reverse polish notation, ou notação polaca inversa), onde o operador segue os dois operandos (e.g.: "2 5 +" seria 7).

```
%option main
   #include <stdio.h>
  #include <stdlib.h>
  int a = 0;
  int b = 0:
%%
  int r;
[+-]?[0-9]+a=b; b=atoi(yytext);
                r=a+b; printf("%d+%d=%d\n", a,b,r); a=b; b=r; r=a-b; printf("%d-%d=%d\n", a,b,r); a=b; b=r; r=a*b; printf("%d*%d=%d\n", a,b,r); a=b; b=r;
[-]
[*]
                r=a/b; printf("%d/%d=%d\n", a,b,r); a=b; b=r;
[/]
.|\r|\n
```

Exemplo final 2: Contador de identificadores

Este exemplo flex pretende ser um contador de identificadores e inteiros num código fonte em qualquer linguagem. Um identificador é definido como uma sequência de um ou mais caracteres alfanuméricos ou underscore (sublinhar). O identificador não pode começar com um caracter numérico.

```
%option novywrap
  #include <stdio.h>
  enum { TOKEN IDENT, TOKEN INT, TOKEN MISC, TOKEN EOF };
%%
[a-zA-Z][a-zA-Z0-9]*
                             return TOKEN IDENT;
[+-]?[0-9]+
                             return TOKEN INT;
                             return TOKEN MISC;
.|\r|\n
<<E0F>>
                             return TOKEN EOF;
%%
```

```
int main()
int num_idents = 0;
int num ints = 0;
int token;
do
      switch( token=yylex() )
            case TOKEN_IDENT:
                                  ++num_idents;
                                  break;
            case TOKEN INT:
                                  ++num_ints;
                                  break;
            /* outro TOKEN *: ignorar */
      while( token != TOKEN EOF );
printf( "Identificadores: %d\n", num idents );
printf( "Inteiros: %d\n",
                                  num ints );
return 0;
}
```

Repare-se que aqui as acções fazem return, saindo assim da função yylex(). Esta é uma forma comum de permitir que a função yylex() seja apenas auxiliar em detectar *tokens*, e não tenha o trabalho central de processamento dos mesmos. Esta será a forma de usar o flex quando avançarmos para o bison.

Exercício final flex

Combine os dois exemplos anteriores, criando uma calculadora de números reais, infixa, mas onde a leitura de cada *token* (elemento) da calculadora é feita pela função main(), chamando o yylex() para ler cada *token*, como o exemplo 2, acima.

Correcção no final da aula seguinte.

Correcção do exercício da aula anterior.

Primeiro exemplo bison

Descarrega o primeiro exemplo bison. É uma calculadora RPN tal como o nosso exemplo final 1 do flex, da aula anterior. Para o compilares só precisas de escrever o comando make*. Em alternativa podes compilá-lo "à mão" com os seguintes comandos:

```
bison -d rpn.y -o rpn.tab.c
flex rpn.l
gcc rpn.tab.c lex.yy.c -Wall -o rpn
```

Ele consiste de 5 ficheiros, que são:

- bison.hairy e bison.simple necessários para algumas versões de bison, tipicamente em Windows. Fazem parte do bison em si e não devem ser alterados.
- Makefile ou Makefile.mak ficheiro que tem os comandos necessários para construir (make) o nosso executável. Nota que podes ter de fazer algumas alterações para o conseguires correr em Linux (vê comentários ao topo do ficheiro).
- rpn.l ficheiro flex que detecta os *tokens* da nossa calculadora.
- rpn.y ficheiro bison que tem as regras gramaticais da nossa calculadora.

Este programa consiste de uma série de variáveis e funções definidas separadamente pelo flex e bison, mas que devem trabalhar em conjunto. Ao nível mais abstracto (da gramática) são as regras bison que trabalham, enquanto que ao nível mais baixo (detecção de tokens) são as regras flex que trabalham.

Vamos começar pelo abstracto, pela visão global de como fazer esta calculadora.

-

^{*} O teu compilador de C tem de ter este executável, caso contrário deves descarregá-lo de outro compilador (e.g.: da GNU) ou executar os comandos individuais à mão.

A gramática da calculadora

Uma operação em RPN tem o seguinte aspecto, e.g.:

$$25 +$$

Mas podemos combinar operações, e.g.:

ou

$$11 + 5 +$$

Em ambos os casos chamamos a estas combinações de operações de "expressões". Isto é um nome comum em linguagens de programação e Matemática. Ambas as expressões acima fazem a conta "2+5".

Então, embora ingenuamente nós possamos definir uma operação RPN como tendo o seguinte aspecto:

operando operador

na realidade cada operando pode ser o resultado de uma operação, e pode então ser uma expressão em si. Então o aspecto de uma operação RPN é:

expressão expressão operador

desde que cada expressão possa também ser definida como simplesmente uma constante numérica. É exactamente isto que encontras ao final do ficheiro rpn.y, na definição de expr.

expr é algo abstracto no ficheiro rpn.y. Não tem um único correspondente real nas operações que escreves na calculadora. É um nome que serve apenas de auxiliar abstracto para descrever o aspecto geral das operações. Chama-se então a este nome de "símbolo não-terminal".

Explicar como fazer gramáticas não faz parte do âmbito das aulas práticas, mas sim das aulas teóricas. Nas aulas práticas vamos estudar apenas como implementar as gramáticas no bison.

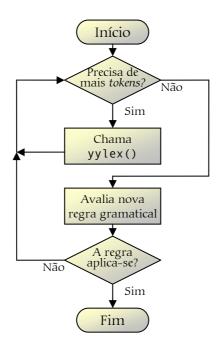
Análise gramatical: yyparse()

O bison (ou melhor, a função yyparse() de análise gramatical gerada pelo bison) precisa de reconhecer qual regra se aplica a cada instante. Para isso, para além da gramática precisar de ter certas características que irás aprender nas aulas teóricas, também precisa de ocasionalmente se referir aos elementos que o utilizador escreve (elementos aos quais se chama de "símbolos terminais" ou tokens).

Esta referência tem o detalhe necessário para cada gramática. Por exemplo, na definição de expr no ficheiro rpn.y, vemos que não quero nem preciso de distinguir o número 1 do número 2 do número 3 e do número 5 (ou outros). Preciso só de saber que encontrei um NUMERO.

Por outro lado, nesta gramática dá-me jeito distinguir as 4 operações suportadas, pelo que tenho os 4 tokens OP_SOMA, OP_SUB, OP_MULT e OP_DIV.

A descrição do "aspecto" de cada símbolo terminal (token) não é do âmbito de yyparse(). Enquanto está a distinguir qual regra se aplica, esta função pode estar a comparar os tokens que já encontrou (mas ainda não "consumiu") com as várias regras disponíveis. Mas quando estes tokens não são suficientes, ela precisa de obter "o próximo token disponível". Isto faz-se chamando automaticamente uma função (yylex()) que deverá resolver esse problema. No nosso caso estamos a usar o flex para criar essa função.



O processamento de yyparse() é então semelhante ao diagrama exibido acima. Ele vai avaliando as regras gramaticais uma a uma até encontrar uma que se aplique, e conforme vai precisando de mais tokens, chama yylex().

Símbolos terminais e valores semânticos

Definimos o aspecto dos símbolos terminais no ficheiro rpn.1, em formato flex. Esse ficheiro deve-te ser familiar e quase tudo deve ser óbvio.

Repara nas expressões regulares triviais que estamos a usar para definir cada token. Repara também como estamos a guardar o valor do número detectado (o chamado valor semântico do token NUMERO) numa variável global, tal como o tivemos de fazer para resolver o exercício final flex da aula anterior. Neste caso usamos uma variável global pré-definida pelo bison para esse efeito: yylval. O tipo de dados que esta variável guarda é o definido na macro YYSTYPE*.

_

^{*} É possível que esta variável global seja uma união de vários tipos para quando a linguagem com que estamos a trabalhar suporta vários tipos (tal como a maior parte das linguagens de programação). Mais detalhes em aula posterior.

No bison temos um atalho para nos referirmos a esta variável: os \$\$, \$1, \$2, etc.:

Aceder a	Aceder a valores semânticos		
\$\$	Valor semântico da regra em si.		
\$#	Valor semântico de cada um dos elementos da regra: \$1 refere-se ao primeiro elemento da regra, \$2 ao segundo, etc Ver exemplo.		

Cada um dos **\$#** estará a referir-se à respectiva variável **yylval**:

- Tal como atribuída na função yylex() que retornou esse token, ou
- Tal como definida pela atribuição \$\$=... na acção da regra gramatical correspondente.

É precisamente por cada regra também ter o seu valor semântico, que o yyparse() consegue encadear expressões umas nas outras.

Interligação entre os ficheiros flex e bison

Ambos os ficheiros se referem às mesmas constantes NUMERO, OP_SOMA, OP_SUB, OP_MULT, OP_DIV e EOL. Podíamos defini-las em ambos os ficheiros, mas se por engano NUMERO tem o valor 1 no rpn.l e o valor 2 no rpn.y (por exemplo) então o código não irá funcionar bem.

O bison tem uma directiva %token que nos permite definir estes *tokens* e posteriormente exportá-los (assim como algumas outras opções) para um ficheiro rpn.tab.h que devemos incluir no nosso ficheiro em C gerado pelo flex. Ficamos assim com um único ponto de definição de *tokens*: o ficheiro bison*.

Mas embora não tenhamos o inverso (um ficheiro .h do flex para o bison), precisamos de usar no ficheiro bison a função yylex() definida pelo flex. Como ela é sempre definida como recebendo nada (void) e devolvendo um inteiro, isto não é problema – temos simplesmente de nos lembrar de a definir como extern no ficheiro bison para evitar erros de ligação (linkage) após a compilação.

_

^{*} Há outra razão para estarmos a usar o **%token** do **bison**: é que em certas situações precisamos de estabelecer no **bison** certas características dos *tokens*, ao mesmo tempo que os "definimos". Mais sobre isto em aula posterior.

Formato do ficheiro bison

O formato do ficheiro bison é quase idêntico ao dos ficheiros flex que temos visto até agora:

```
Definições bison
%%
Regras bison
%%
Código de utilizador em C
```

A secção de definições pode ter:

```
%{
Inicializações de variáveis C e funções/protótipos C
(opcional)
%}
%directiva
```

As regras bison serão definidas em mais detalhe em aula posterior, mas pode ter-se uma ideia do aspecto normal destas regras neste primeiro exemplo.

Exercício

Altera o primeiro exemplo bison para passar a funcionar como uma calculadora infixa.

Simplifica depois o código: as directivas %token geram sempre números acima de 255 (0xFF) para os *tokens* definidos, isto para permitir que um *token* simples de um só caracter seja representado pelo seu próprio código ASCII, como em C (e.g.: 'c'), sem necessitar de directiva %token. Simplifica então os ficheiros rpn.l e rpn.y para que as operações sejam especificadas desta forma.

Correcção do exercício da aula anterior. A resolução necessitava apenas de colocar os operadores entre os operandos na regra expr. Mas isto gera um aviso sobre 16 erros shift/reduce. Para os resolver precisamos de conhecer mais sobre o bison.

Regras bison

As regras bison são definidas da seguinte forma geral:

```
resultado: símbolo<sub>1</sub> símbolo<sub>2</sub> ... { acção<sub>1</sub> }
                     símbolo<sub>3</sub> símbolo<sub>4</sub> ... { acção<sub>2</sub> }
Ι
```

Cada regra tem um nome associado ("resultado" no exemplo acima), e pode ter várias variantes (definidas em linhas diferentes e separadas por um caracter "|"). As várias variantes também podem ser definidas com o nome da mesma regra à esquerda, como em:

```
resultado: símbolo<sub>1</sub> símbolo<sub>2</sub> ... { acção<sub>1</sub> }
resultado: símbolo₃ símbolo₄ ... { acção₂ }
```

Cada variante da regra tem zero ou mais componentes (símbolos terminais ou não-terminais) e, opcionalmente, uma acção (código C) envolvida em {}. Os componentes determinam o aspecto desta variante da regra, em termos de posição e tipo de símbolos.

Cada regra deve terminar com um ";" numa linha independente.

Como funcionam as regras no primeiro exemplo

A regra input do primeiro exemplo diz que os dados oferecidos à calculadora podem ser vazios, ou uma sequência de linhas. Este tipo de regras diz-se "recursivas à esquerda" (devido à parte "input linha") e é preferido em relação às equivalentes "recursivas à direita" (que seriam "linha input" – ver manual do bison).

A segunda regra determina o aspecto válido de cada linha: ou vazia, ou com uma única expressão (em cujo caso exibimos o seu valor).

A terceira e última regra define o aspecto válido de cada expressão em termos de si mesma. Conforme a função yyparse() gerada pelo bison vai subindo

semanticamente das expressões mais simples às mais complexas, as acções das regras respectivas correm e as contas parciais são feitas.

Exemplo de análise gramatical

Descarrega o exemplo "calc-sr" (Calculadora *shift-reduce*) e compila-o. Quando o correres, escreve:

1+2*3

Este exemplo mostra-te os passos que o yyparse() dá para analisar esta (ou qualquer outra) expressão. Estes são de três tipos:

- Shift: ler um novo token dos dados de entrada e colocá-lo numa pilha interna para processamento;
- *Reduce:* reduzir uma combinação de símbolos (terminais e/ou não-terminais) na pilha, a um seu equivalente gramático;
- Accept: Se já não há mais tokens a ler da entrada e se a pilha se reduz ao símbolo não-terminal inicial (neste caso, input), então termina o processamento com sucesso.

Todas as acções do flex correspondem então a *shifts* e todas as do bison correspondem a *reduces*. Com este programa vemos a seguinte sequência de acções:

Pilha :	Tokens Acção
(vazia) 1+2*3	B EOL <i>Reduce</i> : input ← (vazio)
input 1+2*3	3 EOL Shift: 1
input 1 +2*3	B EOL <i>Reduce</i> : expr ← 1
input expr +2*3	3 EOL Shift: +
input expr + 2*3	3 EOL <i>Shift:</i> 2
input expr + 2 *3	B EOL <i>Reduce</i> : expr ← 2
input expr + expr *3	3 EOL Shift: *
input expr + expr *	3 EOL Shift: 3
input expr + expr * 3	EOL <i>Reduce</i> : expr ← 3
input expr + expr * expr	EOL <i>Reduce</i> : * expr ← expr * expr

^{*} Porque não há operadores com maior precedência do que o * nesta calculadora. Ver secção seguinte sobre conflitos.

_

Este exemplo mostra-te dois pontos importantes:

• Existe sempre uma regra inicial. Ela é sempre a 1ª a ser especificada no ficheiro bison (regra input neste caso), mas podemos especificar outra com a declaração:

```
%start símbolo-não-terminal;
```

• Uma gramática bison só estará correcta se puder ser reduzida à regra/símbolo inicial em todas as combinações possíveis da sua linguagem.

Conflitos shift/reduce: %left, %right e %expect

Este tipo de conflitos surgem quando mais do que uma regra se pode aplicar em certas situações e o yyparse() não sabe se deve aplicar (reduce) a regra mais curta ou aceitar o novo token (shift) para aplicar a regra mais longa (que é o que fará por omissão).

Estes conflitos podem ser ignorados, mas podemos resolvê-los de duas formas:

- 1. Associatividade e precedência de operadores, ou
- 2. Dizer ao bison que já contamos com certa quantidade destes conflitos.

O primeiro caso usa-se quando podemos vir a ter ambiguidade com o uso de operadores. E.g., na nossa calculadora infixa:

$$x + y + z$$

Isto resolve-se alterando a declaração %token dos operadores em questão por:

Associatividade de operadores		
%left	Associatividade à esquerda, ou seja, fazemos x+y primeiro.	
%right	Associatividade à direita, ou seja, fazemos y+z primeiro.	
%nonassoc	Sem associatividade: a expressão acima é um erro de sintaxe.	

_

^{*} Na realidade aqui não ocorreu um *shift*, mas um "look-ahead" (ver manual do bison). Mas não vamos entrar em muitos detalhes e assumir que as coisas correm como é aqui descrito, por simplicidade.

Cada uma destas declarações pode levar à frente mais do que um operador. Todos esses terão a mesma precedência. Operadores declarados em declarações diferentes têm maior precedência (são executados primeiro) se forem declarados mais tarde (mais abaixo) no ficheiro bison.

Ou seja, a precedência correcta para as quatro habituais operações matemáticas é:

```
%left OP SOMA OP SUB
%left OP MULT OP DIV
```

A segunda forma de resolver os conflitos surge quando eles são esperados. Por exemplo:

```
IF expr THEN decl
regra:
            IF expr THEN decl ELSE decl
```

Neste caso existe ambiguidade na aplicação das duas variantes da regra. Mas podemos acrescentar

```
%expect 1
```

ao topo do ficheiro bison para que ele espere este conflito, e só gere avisos se encontrar uma quantidade diferente de conflitos.

Exercício 1

Acrescenta à calculadora a capacidade de atribuir valores (expressões) a variáveis, criando-as se necessário. Cada variável é inteira, pode ter um nome arbitrário de até 32 caracteres alfanuméricos ou underscore (mas não pode começar num dígito numérico), e podem haver no máximo 100 variáveis definidas pelo utilizador. A atribuição de variáveis é ela mesma uma expressão, devolvendo o valor atribuído.

Acrescenta também a capacidade da calculadora fazer cálculos com base em decisões, ou seja fazer algo parecido a:

```
if( expr ) expr else expr
sendo a parte do else, opcional.
```

Dicas: as limitações às variáveis são para te facilitar o trabalho. Para cada variável preciso de guardar duas coisas: o nome dela e o valor que ela tem. Existem no máximo 100 variáveis. Então crio um vector de 100 estruturas com:

```
struct s variavel
      char nome[32+1];
      int valor;
      vector[100];
```

Pergunta: porquê 32+1?

É útil criares duas funções auxiliares: uma que pesquisa por uma variável com um dado nome, e outra que a cria se ela não existir. Ambas devem devolver um apontador para o vector, ou NULL se a variável não for encontrada ou o vector estiver cheio e a função não a puder criar.

O ficheiro bison vai precisar de receber do flex o nome da variável para além da indicação que encontrou um nome de variável. Como yylval é um inteiro, faço isso com uma nova variável global que crio. Não te esqueças que ela será definida normalmente num ficheiro e como extern no outro.

Para adicionares a decisão às regras da gramática, não te esqueças de adicionar a detecção dos seguintes *tokens* no ficheiro flex:

Exercício 2

Acrescenta à calculadora o comando

que exibe o resultado de expr no ecrã.

Com isto, altera os níveis superiores abstractos da gramática (regras input e linha) para em vez dela ser "uma sequencia de linhas com expressões" passar a ser "uma sequência de expressões separadas por ';'".

Naturalmente que agora os resultados dos cálculos só são exibidos no ecrã quando o utilizador o pedir explicitamente com print. Isto também significa que o token EOL é agora desnecessário.

Exercício 3

Acrescenta uma nova regra afirm à calculadora. Ela servirá para distinguir expressões de afirmações. Ajusta a calculadora para passar a usar esta regra para if e print. A principal distinção entre expressões e afirmações (statements) é que estes últimos não nos devolvem um valor que possamos usar em cálculos.

Cria a expressão condicional "?" que, tal como em C, serve para fazer um condicional dentro de uma expressão.

No exercício 1 da aula anterior vimos que para passar o nome da variável do flex para o bison precisámos de criar uma nova variável global porque a nossa variável de valor semântico (yylval) já era um inteiro. Mas como podemos então compilar linguagens que podem lidar com vários tipos de dados? Como passamos do flex strings, reais e inteiros para o bison?

Múltiplos tipos de dados semânticos: %union

Este problema resolve-se com recurso à directiva %union. Quando a usamos, devemos deixar de usar o #define YYSTYPE pois yylval vai passar a ser um tipo de dados composto com uma union de C, e vai passar a fazer parte de rpn.tab.h.

Usamos %union tal como em C, da seguinte forma:

```
%union {
      int valor_inteiro;
      char nome de variavel[32+1];
```

Podemos ter a quantidade e tipo de membros (variáveis) que desejarmos dentro desta union. Nota no entanto que esta %union não termina com ";" ao contrário de C.

Claro que agora precisamos de informar o bison e o flex de qual membro do yylval nos referimos em cada regra.

No flex isto é trivial. yylval é uma union C e então:

```
[0-9]+ { yylval.valor_inteiro = atoi(yytext); ... }
```

No bison, como nos referimos aos valores semânticos com \$\$, \$1, \$2, etc., podemos fazer também:

```
$1.valor inteiro
```

ou definimos qual o tipo de dados a cada símbolo terminal ou não-terminal para o bison determinar o tipo de cada \$\$, etc., automaticamente:

```
%token <valor inteiro> símbolo-terminal
%type <valor inteiro> símbolo-não-terminal
```

%type é usado apenas para definir o membro da %union em símbolos nãoterminais.

A partir daqui podemos usar \$\$, \$1, \$2, etc., sem especificar o membro da %union, que o bison saberá fazê-lo sozinho.

O seguinte exemplo define e distingue operações de soma (entre inteiros) e concatenação (entre *strings*):

Tem atenção que este exemplo tem uma forma ingénua de lidar com *strings* (impedindo *strings* maiores de 1000 caracteres, mas não validando este limite). Os teus programas deveriam ser mais robustos.

Exercício 1

Altera o exercício 1 da aula anterior para passar a usar **%union** e passar o nome da variável também em **yylval**.

Exercício 2

Adiciona suporte a tipos de dados à tua calculadora. Ela deve passar a suportar variáveis reais para além de inteiras.

Não convertas todos os números lidos para reais. O comportamento da calculadora deve ser como em C: uma operação que tenha ambos os argumentos inteiros deve fazer o cálculo em inteiro (mesmo uma divisão). Uma operação que tenha pelo menos um dos argumentos reais, deve converter ambos para reais e fazer o cálculo em número real. O print expr também deve exibir um inteiro ou real dependendo do tipo de dados do resultado da expressão.

Bibliografia

[FLEX]

"flex: The Fast Lexical Analyzer", site oficial No site da SourceForge em: http://flex.sourceforge.net/

[BISON]

"Bison – GNU parser generator", site oficial No site da GNU em: http://www.gnu.org/software/bison/bison.html

[GNUWIN32]

"GnuWin32", Utilitários da GNU compilados para Windows. Inclui flex, bison e make. No site da SourceForge em: http://gnuwin32.sourceforge.net/

[C-PROG]

"The C Programming Language", Prentice Hall Software Series, Brian W. Kernighan e Dennis M. Ritchie Na Amazon do Reino Unido, em: http://www.amazon.co.uk/C-Programming-Language-2nd/dp/0131103628/

(mais em breve)